Classificação de Notícias com algoritmos de Machine Learning

Larissa Martins Sá
Ciência e Tecnologia
Universidade Federal de São Paulo
São José dos Campos, Brasil
lm.sa@unifesp.br

Julia Souza Belmonte Lopes
Ciência e Tecnologia
Universidade Federal de São Paulo
São José dos Campos, Brasil
julia.belmonte@unifesp.br

Katherine M. van den Mosselaar
Ciência e Tecnologia
Universidade Federal de São Paulo
São José dos Campos, Brasil
kmvd.mosselaar@unifesp.br

***Abstract*—The rapid spread of fake news on the internet represents a serious challenge to information reliability and public trust. This study explores the application of multiple supervised machine learning algorithms—Random Forest, Multinomial Naive Bayes, Support Vector Machine (SVM), Logistic Regression, and K-Nearest Neighbors (KNN)—to automatically classify news articles as fake or real. Using the "Fake and Real News Dataset" from Kaggle, we performed thorough text preprocessing and feature extraction via TF-IDF vectorization. The models were evaluated based on accuracy, precision, recall, F1-score, and execution time. Among them, SVM achieved perfect classification accuracy, while Naive Bayes and Logistic Regression also delivered strong performance with efficient execution. This work contributes to Sustainable Development Goal 16 (Peace, Justice and Strong Institutions) by advancing automated tools to detect and reduce misinformation online.**

***Keywords*—Fake news detection, Machine Learning, Natural Language Processing, Random Forest, Naive Bayes, KNN.**

I. Introdução

A disseminação de notícias falsas tem se tornado um problema crescente na sociedade atual, impactando decisões individuais e coletivas em diversas áreas, como política, saúde e economia. O rápido avanço das redes sociais e a facilidade de compartilhamento de informações ampliam a propagação de conteúdos não verificados, tornando essencial o desenvolvimento de ferramentas automáticas capazes de identificar e classificar notícias verdadeiras e falsas. Este trabalho apresenta uma abordagem para a detecção automática de notícias falsas utilizando técnicas de processamento de linguagem natural (PLN) e algoritmos de aprendizado supervisionado. Foram utilizados dois conjuntos de dados contendo notícias verdadeiras e falsas, nos quais aplicamos pré-processamento textual, incluindo limpeza, remoção de stopwords e vetorização por TF-IDF para transformar os textos em representações numéricas. Cinco algoritmos foram implementados e avaliados para a tarefa de classificação: Naive Bayes Multinomial, Random Forest, Regressão Logística, Support Vector Machine (SVM) e K-Nearest Neighbors (KNN). O desempenho de cada modelo foi comparado com base em métricas como acurácia, precisão, recall e f1-score, buscando identificar a melhor abordagem para distinguir notícias verdadeiras de falsas. Os resultados obtidos demonstram que modelos como SVM e Naive Bayes alcançaram altas taxas de acurácia, indicando a eficácia das técnicas de PLN combinadas com algoritmos de machine learning para o desafio da detecção de notícias falsas.

II. Trabalhos Relacionados

A. Oliveira et al. (2019) – Inteligência Artificial Aplicada a Detecção de Fake News

Este trabalho propõe uma abordagem com duas vertentes:

- **Abordagem A**: uso de algoritmos clássicos de aprendizado de máquina, como Árvore de Decisão, Naive Bayes e SVM.
- **Abordagem B**: utilização de redes neurais (deep learning).

No melhor cenário, a acurácia alcançada foi de 92,36%

B. Garcia (2023) – Detecção de Fake News utilizando Aprendizado de Máquina

Dissertação de mestrado da UNESP (Bauru), que:

- Realiza estudo aprofundado de técnicas de processamento de linguagem natural e aprendizado de máquina aplicadas à classificação de notícias falsas em português.
- Cria novos corpora de notícias (verdadeiras e falsas) para incentivar pesquisas nessa área.

Esses trabalhos abrangem uma variedade de métodos (desde algoritmos clássicos até deep learning), destacando também a importância de corpora mais representativos e modernos em português, pontos que se alinham fortemente com o nosso estudo.

III. Metodologia

A metodologia adotada neste projeto foi dividida em cinco etapas principais: (1) aquisição e exploração dos dados, (2) pré-processamento dos textos, (3) vetorização com TF-IDF, (4) separação dos dados em treino e teste, e (5) aplicação e avaliação de diferentes algoritmos de aprendizado supervisionado. Abaixo, cada uma dessas etapas é descrita em detalhes.

A. Aquisição e exploração dos dados

Para a realização deste trabalho, foram utilizados dois conjuntos de dados públicos disponíveis no Kaggle sob o nome "Fake and Real News Dataset". Um arquivo (Fake.csv) contém notícias falsas e o outro (True.csv) contém notícias

verdadeiras. Ambos os datasets apresentam as colunas title, text, subject e date. Após a leitura dos dados utilizando a biblioteca Pandas, foi feita uma análise exploratória básica para verificar a quantidade de instâncias, a distribuição das classes e a presença de valores duplicados ou ausentes. Foi observado que o conjunto contém um total de 44.898 notícias, sendo 23.481 falsas e 21.417 verdadeiras.

B. Pré-processamento dos Textos

Como etapa fundamental do processamento de linguagem natural, foi aplicado um pré-processamento nas colunas de texto das notícias. Esse processo teve como objetivo padronizar os dados textuais e eliminar ruídos que poderiam impactar negativamente o desempenho dos algoritmos. As seguintes transformações foram aplicadas a cada texto:

- Conversão para letras minúsculas;
- Remoção de números;
- Remoção de pontuações;
- Remoção de espaços em branco extras;
- Remoção de stopwords com NLTK (como “the”, “is”, “in”);

O texto limpo foi salvo em uma nova coluna chamada text_limpo. Em seguida, foi adicionado uma coluna label para identificar a classe de cada notícia: 0 para falsas e 1 para verdadeiras. Por fim, os dois conjuntos foram unidos em um único DataFrame chamado noticias.

C. Vetorização com TF-IDF

Foi utilizado o TfidfVectorizer da biblioteca scikit-learn com o parâmetro max_features=1500, o que significa que apenas as 1500 palavras mais informativas foram mantidas. Essa técnica atribui pesos às palavras com base em sua frequência no documento e em sua raridade no corpus. Foram realizados testes com diferentes quantidades de palavras (por exemplo, 2500 e 5000), sendo observado que a redução do vocabulário pode beneficiar modelos como Random Forest ao reduzir a dimensionalidade e o risco de overfitting.

D. Separação dos Dados

Os dados foram divididos em conjuntos de treinamento (80%) e teste (20%) utilizando a função `train_test_split` com `stratify=y` para manter a proporção entre as classes. Essa divisão garante que o modelo seja treinado em um subconjunto dos dados e avaliado em dados nunca vistos.

E. Treinamento e avaliação dos modelos

Cinco algoritmos supervisionados foram treinados e avaliados neste trabalho:

Naive Bayes Multinomial: acurácia de 94%.

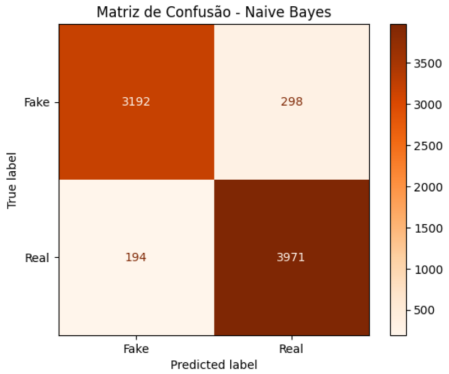

Fig. 1. Matriz de Confusão Naive Bayes

Random Forest: com 100 árvores e profundidade máxima de 10, teve acurácia de 99%.

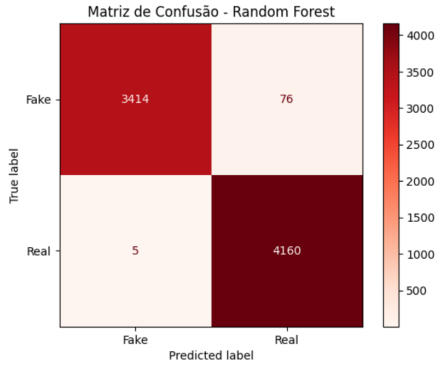

Fig. 2. Matriz de Confusão Random Forest

Regressão Logística: alcançou 99% de acurácia com 1000 iterações.

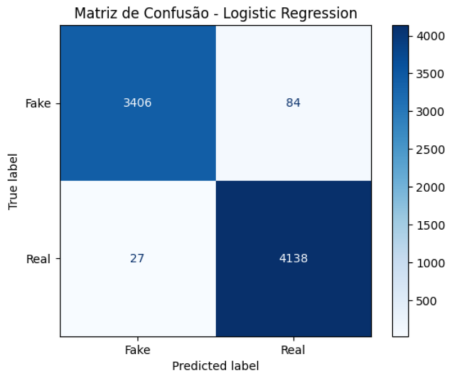

Fig. 3. Matriz de Confusão Regressão Logística

SVM: obteve acurácia de 99%.

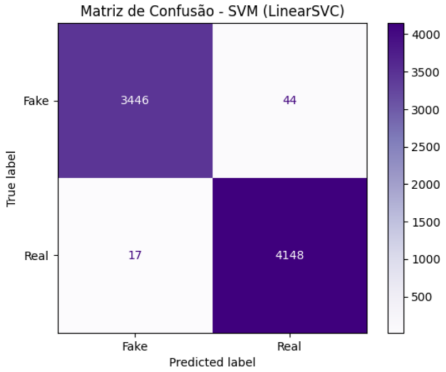

Fig. 4. Matriz de Confusão SVM

KNN: teve o pior desempenho, com 70% de acurácia.

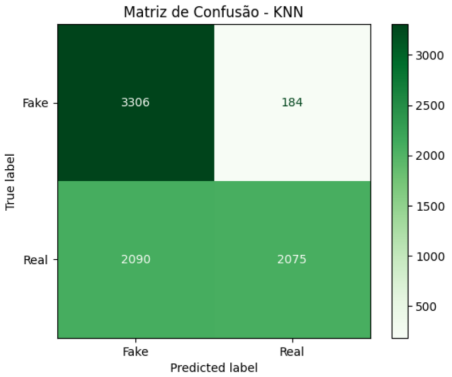

Fig. 5. Matriz de Confusão KNN

As métricas utilizadas foram acurácia, precisão, recall e f1-score. A avaliação foi feita com `classification_report` do `scikit-learn`.

ALGORITMOS DE CLASSIFICAÇÃO

Foram aplicados cinco algoritmos de aprendizado supervisionado para a tarefa de classificação binária entre notícias falsas e verdadeiras. Cada algoritmo foi treinado sobre os vetores TF-IDF e avaliado com base em métricas como acurácia, precisão, recall e F1-score.

F. Random Forest

O Random Forest é um algoritmo de ensemble que constrói múltiplas árvores de decisão sobre subconjuntos aleatórios do conjunto de dados e combina seus resultados por votação majoritária. Essa abordagem melhora a capacidade de generalização do modelo e reduz o risco de overfitting.

Neste trabalho, foi utilizada uma floresta com profundidade limitada (max_depth=10), o que ainda assim apresentou desempenho competitivo, evidenciando sua eficácia na identificação de padrões linguísticos em textos.

G. Multinomial Naive Bayes

O Naive Bayes é um classificador probabilístico baseado no Teorema de Bayes, assumindo independência entre os atributos. Apesar dessa suposição simplificadora, ele é notoriamente eficiente em tarefas de classificação de texto, especialmente com representações esparsas como TF-IDF. O modelo utilizado foi o Multinomial Naive Bayes, ideal para contagens ou frequências de palavras, conseguindo associar probabilisticamente os termos relevantes a cada classe.

H. Suporte de Vetores de Máquina (SVM)

A SVM é um algoritmo que busca encontrar o hiperplano que maximiza a separação entre as classes, sendo especialmente eficaz em espaços de alta dimensão, como os gerados por vetores de texto. Neste projeto, foi utilizada uma SVM com kernel linear, uma escolha apropriada para dados esparsos e linearmente separáveis. O modelo apresentou desempenho excepcional, mesmo sem ajustes complexos de hiperparâmetros.

I. Regressão Logística

A Regressão Logística é um modelo linear amplamente utilizado para tarefas de classificação binária. Ela estima a probabilidade de uma amostra pertencer a determinada classe com base em uma função logística (sigmoide). É especialmente eficaz em espaços vetoriais de alta dimensão e mostrou bom desempenho com dados vetorizados por TF-IDF. No experimento, mesmo com um número limitado de iterações, o modelo apresentou resultados competitivos, destacando-se pelo seu equilíbrio entre simplicidade e eficiência.

J. K-Nearest Neighbors (KNN)

O algoritmo KNN classifica uma nova amostra com base nas classes dos K exemplos mais próximos, medindo a distância no espaço vetorial. Apesar de sua simplicidade, o KNN teve o pior desempenho entre os modelos testados neste projeto, o que pode ser atribuído à alta dimensionalidade dos vetores TF-IDF e à natureza esparsa dos dados, que afetam negativamente o cálculo das distâncias.

IV. ANÁLISE EXPERIMENTAL

CONJUNTO DE DADOS

O experimento utilizou o conjunto de dados *"Fake and Real News Dataset"*, amplamente utilizado para tarefas de classificação binária envolvendo veracidade de conteúdo textual. O dataset foi dividido em dois arquivos principais:

- `True.csv`: Contendo 21.417 registros de notícias verdadeiras.
- `Fake.csv`: Contendo 23.481 registros de notícias falsas.

Cada entrada apresenta as seguintes colunas: *title* (título da notícia), *text* (corpo da notícia), *subject* (tema principal) e *date* (data da publicação). Após a limpeza e concatenação dos dois conjuntos, obteve-se um corpus unificado com 38.271 registros.

Os dados foram balanceados em sua maioria, com distribuição próxima entre classes 0 (falsas) e 1 (verdadeiras),

o que contribui para uma avaliação justa dos algoritmos supervisionados sem necessidade de técnicas de balanceamento.

Configuração do algoritmo e do ambiente computacional

Todos os experimentos foram realizados em um ambiente local com as seguintes especificações:

- Sistema Operacional: macOS 10.15.7 (Catalina)
- Processador: Intel Core i5
- Memória RAM: 8 GB
- Ambiente Python: Python 3.12 com Anaconda

As bibliotecas utilizadas foram: `pandas`, `numpy` (manipulação de dados), `nltk` (pré-processamento textual) e `scikit-learn` (modelagem e avaliação dos algoritmos).

Os algoritmos de aprendizado supervisionado testados foram:

- Multinomial Naive Bayes
- Random Forest (com até 100 árvores e profundidade 10)
- Support Vector Machine (SVM com kernel linear)
- Logistic Regression (com 1000 iterações)
- K-Nearest Neighbors (K = 5)

A vetorização dos textos foi feita com TF-IDF, utilizando os 1.500 termos mais relevantes (com testes adicionais para 2.500 e 5.000 termos).

Critérios de Análise

Os modelos foram avaliados com base nas seguintes métricas clássicas da literatura de classificação:

- **Acurácia**: Proporção total de previsões corretas sobre o total de amostras.
- **Precisão**: Proporção de amostras classificadas como positivas que realmente são positivas.
- **Recall (Sensibilidade)**: Proporção de amostras positivas que foram corretamente identificadas.
- **F1-score**: Média harmônica entre precisão e recall, útil quando há interesse em equilíbrio entre os dois.

A divisão dos dados em treino e teste foi feita utilizando 80% para treino e 20% para teste, com estratificação para manter a proporção de classes.

Resultados e Discussão

Os resultados dos modelos testados podem ser resumidos na Tabela I.

TABLE I
RESULTADOS DOS ALGORITMOS TESTADOS

Algoritmo	Acurácia	Precisão	Recall	F1-Score
SVM	0.99	0.99	0.99	0.99
Naive Bayes	0.94	0.93	0.94	0.93
Logistic Regression	0.99	0.99	0.98	0.99
Random Forest	0.99	0.99	0.99	0.99
KNN	0.70	0.77	0.72	0.70

Para melhor visualização dos resultados obtidos segue os gráficos comparando os cinco modelos considerando a acurácia, precisão, recall, F1-score e tempo de execução:

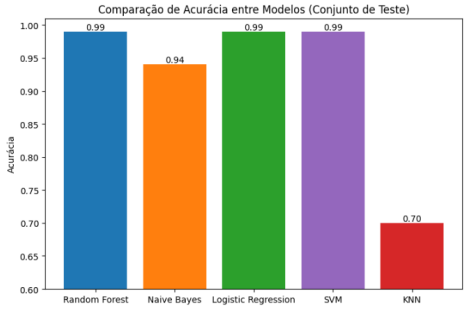

Fig. 6. Gráfico Acurácia

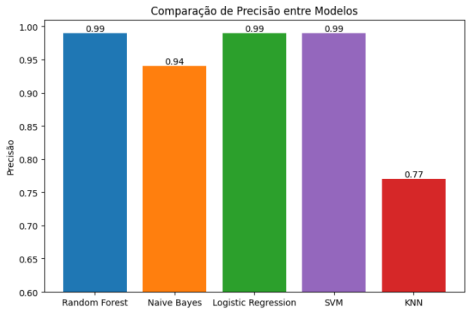

Fig. 7. Gráfico Precisão

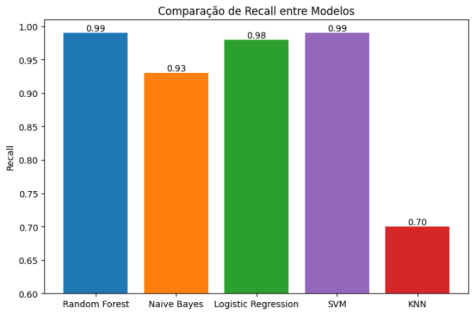

Fig. 8. Gráfico Recall

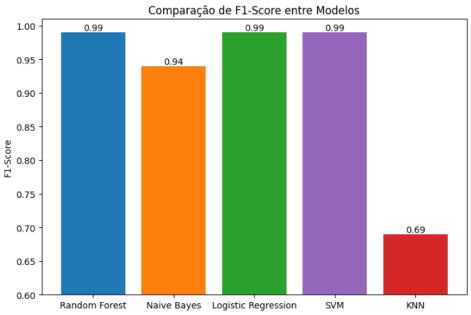

Fig. 9. Gráfico F1-Scores

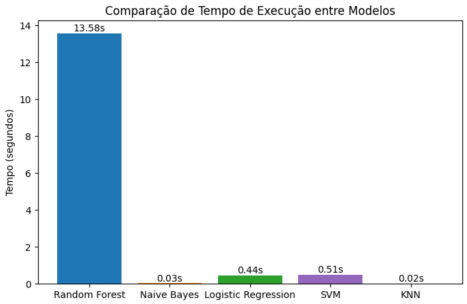

Fig. 10. Gráfico Tempo de Execução

Este trabalho apresentou uma abordagem de classificação de notícias falsas e verdadeiras utilizando técnicas de Processamento de Linguagem Natural (PLN) e algoritmos de aprendizado supervisionado. O pré-processamento textual, aliado à vetorização TF-IDF, demonstrou ser uma etapa fundamental para converter os dados textuais em representações numéricas significativas e adequadas para análise automática.

Dentre os cinco modelos testados, os algoritmos Support Vector Machine (SVM) com kernel linear, Regressão Logística e Random Forest obtiveram resultados muito próximos, alcançando acurácias de aproximadamente 99%, evidenciando a alta capacidade desses modelos para tarefas de classificação textual quando combinados com representações esparsas como TF-IDF.

O classificador Naive Bayes também se mostrou eficiente, atingindo 94% de acurácia, destacando sua simplicidade e velocidade na execução, o que o torna adequado para contextos que exigem modelos leves e rápidos.

Por outro lado, o algoritmo K-Nearest Neighbors (KNN) apresentou desempenho inferior, com acurácia de 70%, revelando limitações na aplicação a dados de alta dimensionalidade como os vetores TF-IDF.

De forma geral, os resultados demonstram que modelos lineares simples e algoritmos baseados em árvores, quando combinados com pré-processamento eficaz e vetorização adequada, são altamente capazes de identificar padrões em textos jornalísticos e classificar a veracidade das informações com alta precisão.

Este estudo contribui para a área de detecção automática de fake news e destaca a importância de métodos de PLN na construção de ferramentas que auxiliem na verificação de informações. Como trabalhos futuros, propõe-se explorar redes neurais profundas (como LSTM ou transformers) e incorporar metadados (como data ou fonte da notícia) para refinar ainda mais a capacidade preditiva dos modelos.

References

[1] GeeksforGeeks, "K-Nearest Neighbours," [Online]. Available: https://www.geeksforgeeks.org/machine-learning/k-nearest-neighbours/. [Acesso em: 12-Jul-2025].

[2] Scikit-learn, "Support Vector Machines — scikit-learn 1.3.0 documentation," [Online]. Available: https://scikit-learn.org/stable/modules/svm.html. [Acesso em: 12-Jul-2025].

[3] Scikit-learn, "RandomForestClassifier — scikit-learn 1.3.0 documentation," [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html. [Acesso em: 12-Jul-2025].

[4] Scikit-learn, "LogisticRegression — scikit-learn 1.3.0 documentation," [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html. [Acesso em: 12-Jul-2025].

[5] Google Cloud, "What is machine learning?," [Online]. Available: https://cloud.google.com/learn/what-is-machine-learning?hl=pt-BR. [Acesso em: 12-Jul-2025].

[6] L. M. R. Oliveira, *Inteligência Artificial Aplicada a Detecção de Fake News*, Universidade Federal do Maranhão (UFMA), São Luís, 2019. [Online]. Available: https://monografias.ufma.br/jspui/handle/123456789/4251

[7] G. L. Garcia, *Detecção de Fake News Utilizando Aprendizado de Máquina*, Dissertação de Mestrado, Universidade Estadual Paulista (UNESP), Bauru, 2023. [Online]. Available: https://repositorio.unesp.br/handle/11449/242304